

INFORME TÉCNICO

Detección de pilares y forjados mediante YOLO11s

Resultados experimentales, comparación de versiones y selección del modelo



Caso piloto: estructura de hormigón utilizada para la adquisición y anotación de imágenes.

Sistema integrado de fotogrametría UAV y detección de objetos mediante YOLO para la caracterización de edificios en procesos de deconstrucción selectiva

Alumna	Ainhoa Díaz Contreras
Máster	Robótica y Automatización de Procesos
Edición	2025-2026
Contenido	Apartado de visión artificial y detección YOLO

Resumen ejecutivo

El presente informe documenta el desarrollo experimental del módulo de detección de elementos estructurales mediante YOLO11s aplicado al edificio piloto. El objetivo fue transformar las imágenes capturadas en información semántica útil para la identificación automática de dos clases: pilar y forjado. El proceso comprendió la selección y anotación manual de imágenes, la generación de versiones del conjunto de datos en Roboflow, el entrenamiento del detector y la evaluación comparativa de tres hitos representativos: V1, V8 y V13.

La V1 actuó como línea base con 16 imágenes y solo 2 imágenes de prueba. La V8 amplió el conjunto hasta 78 imágenes con una partición 70/20/10 (55 de entrenamiento, 16 de validación y 7 de prueba), y logró el mayor mAP@50 (23,0 %) y el mayor recall (30,0 %). La V13 empleó 105 imágenes y una partición 70/15/15; obtuvo la mayor precisión (66,7 %) y el mejor F1 (30,6 %), reduciendo de forma notable los falsos positivos. En consecuencia, la V13 se selecciona como configuración preferente para la demostración e integración del prototipo, mientras que la V8 se conserva como referencia por su mejor capacidad media de detección.

Conclusión principal

La V13 no es superior en todas las métricas, pero ofrece el comportamiento más conservador y fiable entre las versiones analizadas. La selección se justifica por la reducción de falsos positivos, el mejor F1 y un conjunto de prueba mayor. El resultado debe considerarse una validación de concepto, no un modelo listo para producción.

1. Objetivo y alcance

El módulo YOLO se incorporó al flujo general del TFM para complementar la reconstrucción fotogramétrica con información semántica. La detección automática permite localizar elementos visibles en las imágenes y asociarlos a categorías constructivas, generando una base para su posterior representación en el gemelo digital y para la planificación de operaciones de deconstrucción selectiva.

- Clases definidas: pilar y forjado.
- Arquitectura utilizada: YOLO11 Object Detection, tamaño Small (YOLO11s).
- Entorno de preparación, entrenamiento y evaluación: Roboflow.
- Checkpoint inicial indicado por la plataforma: COCOs.
- Preprocesado común: Auto-Orient y redimensionado Stretch a 640 × 640 píxeles.


2. Preparación del conjunto de datos

2.1 Selección y anotación

Las imágenes procedentes de la campaña fotográfica del edificio fueron cargadas en un proyecto de detección de objetos. Para cada imagen se dibujaron cajas delimitadoras alrededor de los elementos visibles, procurando ajustar el rectángulo al área ocupada por el objeto y mantener criterios consistentes entre fotografías. La anotación se concentró en dos componentes estructurales fácilmente reconocibles en la estructura abierta del caso piloto.



Imagen original del edificio



Ejemplo de caja delimitadora para la clase pilar

Figura 1. Imagen del caso piloto y ejemplo del proceso de anotación manual en Roboflow. Fuente: elaboración propia.

2.2 Preprocesado

Para homogeneizar la entrada del detector, las versiones analizadas utilizaron orientación automática y redimensionado a 640×640 píxeles mediante la opción Stretch. Esta configuración permitió mantener constante la resolución de entrada durante los entrenamientos y comparar los resultados sin introducir cambios simultáneos en la arquitectura.




Figura 2. Configuración de redimensionado a 640×640 píxeles empleada en Roboflow.

3. Diseño experimental

Se generaron varias versiones del conjunto de datos durante el proceso iterativo. Para el análisis final se seleccionaron tres hitos que representan la evolución del prototipo: V1 como línea base, V8 como versión con mejor mAP@50 y recall, y V13 como versión con mayor precisión y F1. Todas se entrenaron con YOLO11s.

Versión	Imágenes	Train / valid / test	Test	Confianza óptima	Papel en el análisis
V1	16	11 / 3 / 2 (69/19/12 aprox.)	2	2 %	Línea base y verificación del flujo
V8	78	55 / 16 / 7 (70/20/10)	7	12 %	Mayor mAP@50 y recall
V13	105	74 / 16 / 15 (70/15/15)	15	44 %	Mayor precisión y F1; modelo seleccionado

Tabla 1. Configuración y función de las versiones seleccionadas para el análisis comparativo.

La confianza óptima es el umbral en el que Roboflow presenta el mejor equilibrio F1 para cada modelo. Por ello, las matrices de confusión y los recuentos por clase deben interpretarse en el umbral propio de cada versión. La diferencia de umbrales es también indicativa de la evolución del detector: V1 solo alcanza su mejor equilibrio con un umbral extremadamente bajo (2 %), mientras que V13 mantiene su punto óptimo en 44 %.

4. Resultados por versión

4.1 Versión V1: línea base

La V1 se entrenó con 16 imágenes, distribuidas en 11 imágenes de entrenamiento, 3 de validación y 2 de prueba. El reducido tamaño del test condiciona por completo la interpretación de las métricas. Roboflow advierte expresamente que un conjunto de prueba de 2 imágenes es insuficiente para una evaluación fiable.

mAP@50	Precisión	Recall	F1	Confianza óptima
5,0 %	4,5 %	50,0 %	8,3 %	2 %




Figura 3. Evaluación global de la versión V1 y explorador de métricas de producción.




Figura 4. Matriz de confusión de la V1 al 2 % de confianza.

La matriz de confusión muestra una única detección correcta de pilar, un forjado no detectado y un volumen muy elevado de falsos positivos: 9 predicciones falsas de forjado y 10 de pilar. El recall del 50 % no representa un buen comportamiento global, sino el efecto de evaluar únicamente dos instancias reales. La precisión del 4,5 % y el F1 del 8,3 % confirman que la V1 funciona únicamente como prueba de concepto inicial.

4.2 Versión V8: mejora de la capacidad de detección

La V8 amplió el conjunto hasta 78 imágenes y utilizó una partición 70/20/10: 55 imágenes para entrenamiento, 16 para validación y 7 para prueba. El modelo se evaluó, por tanto, sobre 7 imágenes de test. Esta versión alcanzó el valor más alto de mAP@50 entre las tres seleccionadas (23,0 %) y el recall más elevado de las versiones maduras (30,0 %). El umbral óptimo aumentó hasta el 12 %, reflejando una mayor separación entre detecciones útiles y ruido.

mAP@50	Precisión	Recall	F1	Confianza óptima
23,0 %	25,0 %	30,0 %	27,3 %	12 %




Figura 5. Evaluación global de la versión V8 y umbral óptimo del 12 %.




Figura 6. Matriz de confusión de la V8 al 12 % de confianza.

En la V8 se detectaron correctamente 3 de los 5 forjados presentes en el test, mientras que 2 quedaron como falsos negativos. Para la clase pilar no se registraron aciertos: los 3 pilares reales fueron omitidos. Además, se produjeron 3 falsos positivos para cada clase. Por tanto, la V8 mejora claramente el comportamiento medio, pero sigue mostrando una dificultad específica para reconocer pilares y una precisión global limitada.

4.3 Versión V13: reducción de falsos positivos

La V13 se generó con 105 imágenes y un reparto 70 % entrenamiento, 15 % validación y 15 % prueba, equivalente a 15 imágenes en el test. El umbral óptimo se situó en el 44 %, muy por encima de las versiones anteriores. Aunque el mAP@50 y el recall descendieron ligeramente respecto a la V8, la precisión aumentó hasta el 66,7 % y el F1 alcanzó el mejor valor de la comparación (30,6 %).

mAP@50	Precisión	Recall	F1	Confianza óptima
20,6 %	66,7 %	19,8 %	30,6 %	44 %




Figura 7. Evaluación global de la versión V13 y umbral óptimo del 44 %.




Figura 8. Matriz de confusión de la V13 al 44 % de confianza.

La matriz de confusión registra 2 forjados y 1 pilar correctamente detectados. Permanecen 5 forjados y 8 pilares como falsos negativos, pero los falsos positivos se reducen a 2, ambos asociados a la clase pilar. El aumento de precisión se debe, por tanto, a un comportamiento más conservador: el modelo emite menos detecciones, pero una proporción mayor de ellas es correcta.

5. Comparación V1 - V8 - V13

Versión	mAP@50	Precisión	Recall	F1	Test
V1	5,0 %	4,5 %	50,0 %	8,3 %	2
V8	23,0 %	25,0 %	30,0 %	27,3 %	7
V13	20,6 %	66,7 %	19,8 %	30,6 %	15

Tabla 2. Comparación de las métricas globales de las versiones V1, V8 y V13.




Figura 9. Comparación gráfica de mAP@50, precisión, recall y F1.




Figura 10. Evolución del número de imágenes, tamaño del test y umbral de confianza óptimo.

5.1 Evolución cuantitativa

Entre V1 y V8, el mAP@50 aumenta 18,0 puntos porcentuales y el F1 mejora 19,0 puntos, lo que evidencia que la ampliación y revisión del conjunto de datos permitió que el detector comenzara a aprender patrones útiles. La aparente reducción del recall frente a V1 no debe interpretarse como un retroceso, porque el 50 % de V1 se obtuvo sobre solo dos imágenes y con un umbral de confianza del 2 %.

Entre V8 y V13 se produce un cambio de perfil. El mAP@50 disminuye 2,4 puntos y el recall baja 10,2 puntos; sin embargo, la precisión aumenta 41,7 puntos y el F1 mejora 3,3 puntos. La V13 reduce la emisión de detecciones incorrectas y desplaza el umbral óptimo desde el 12 % hasta el 44 %. Este comportamiento es coherente con un detector más selectivo.

5.2 Interpretación operativa

En una aplicación de apoyo a la deconstrucción, un falso positivo puede generar una identificación errónea de un elemento estructural y trasladar información incorrecta al inventario o al gemelo digital. Por esta razón, la mejora de precisión de la V13 resulta relevante. No obstante, el bajo recall implica que la salida automática no sustituye la revisión técnica: el sistema debe utilizarse como herramienta de asistencia, con validación humana de las detecciones y posibilidad de completar manualmente los elementos omitidos.

Criterio de selección

Se propone la V13 como modelo final del prototipo por su precisión del 66,7 %, su mejor F1 y su test de 15 imágenes. La V8 se mantiene como referencia experimental por presentar el mayor mAP@50 y recall. La decisión responde al objetivo operativo de reducir falsas identificaciones, no a una superioridad absoluta en todas las métricas.

6. Limitaciones de la evaluación

Los resultados deben interpretarse como una validación preliminar. Las propias recomendaciones de Roboflow indican que los conjuntos de prueba de V1, V8 y V13 son inferiores a 50 imágenes, umbral que la plataforma señala como referencia mínima para una evaluación más fiable. Además, los modelos no se evaluaron sobre un conjunto de test fijo: cada cambio de split modifica la composición de las imágenes de prueba, por lo que la comparación entre versiones combina el efecto del entrenamiento con el efecto del muestreo.

- Tamaño reducido del conjunto de datos y del test, especialmente en V1 y V8.
- Diferentes imágenes de prueba entre versiones, lo que limita la comparación estrictamente controlada.
- Pocas instancias de cada clase en los test; la clase pilar concentra la mayoría de falsos negativos.
- Las fotografías proceden de un único edificio, por lo que no se ha demostrado generalización a otras tipologías, materiales o condiciones de iluminación.
- Las métricas dependen del umbral de confianza óptimo de cada versión; los recuentos de la matriz no deben compararse sin considerar dicho umbral.

Para una validación posterior se recomienda reservar un conjunto de prueba fijo e independiente, aumentar el número de instancias anotadas por clase, incorporar fotografías de otros edificios y repetir el entrenamiento con varias semillas o mediante validación cruzada. Estas mejoras permitirían estimar la variabilidad de las métricas y comprobar la capacidad de generalización.

7. Conclusiones

El proceso experimental demuestra la viabilidad de entrenar un detector YOLO11s para localizar pilares y forjados en imágenes del edificio piloto. La evolución desde la V1 hasta la V13 confirma que el aumento y la revisión del conjunto de datos permiten pasar de un modelo prácticamente no operativo a un detector capaz de producir identificaciones útiles, aunque todavía incompletas.

La V1 valida el flujo técnico, pero sus métricas carecen de robustez por el tamaño mínimo del test y el elevado número de falsos positivos. La V8 representa el mayor avance en capacidad de detección, alcanzando el mejor mAP@50 y recall. La V13 introduce un comportamiento más selectivo, con una precisión del 66,7 %, un F1 del 30,6 % y una reducción marcada de falsos positivos. Por ello se considera la configuración más adecuada para la integración demostrativa en el sistema, siempre bajo supervisión humana.

En términos académicos, el resultado no debe presentarse como un modelo óptimo ni listo para producción. Se trata de una prueba de concepto funcional que permite validar el componente de visión artificial dentro del flujo integrado de fotogrametría, detección semántica y gemelo digital. La principal línea de mejora consiste en ampliar y diversificar el dataset, especialmente para la clase pilar, y establecer un protocolo de evaluación con un test fijo y más representativo.

8. Texto propuesto para incorporar al repositorio

La detección de elementos mediante visión artificial se implementó mediante un modelo YOLO11s entrenado en Roboflow para reconocer las clases pilar y forjado. Las imágenes del edificio piloto fueron anotadas manualmente mediante cajas delimitadoras y sometidas a orientación automática y redimensionado a 640×640 píxeles. El proceso se desarrolló de forma iterativa, generando distintas versiones del dataset y comparando su rendimiento mediante mAP@50, precisión, recall y F1.

La versión inicial V1, entrenada con 16 imágenes y evaluada sobre solo 2 imágenes de prueba, obtuvo un mAP@50 del 5,0 %, una precisión del 4,5 %, un recall del 50,0 % y un F1 del 8,3 %. El elevado recall no resultó representativo debido al tamaño del test y al gran número de falsos positivos. Tras ampliar el conjunto de datos, la V8 se configuró con una partición 70/20/10 (55 imágenes de entrenamiento, 16 de validación y 7 de prueba) y alcanzó el mayor mAP@50 (23,0 %) y recall (30,0 %), aunque mantuvo una precisión limitada del 25,0 %. Finalmente, la V13, con 105 imágenes y un reparto 70/15/15, alcanzó una precisión del 66,7 % y el mejor F1 (30,6 %), con un mAP@50 del 20,6 % y un recall del 19,8 %.

La V13 fue seleccionada para la integración demostrativa por reducir de manera significativa las falsas detecciones y presentar el mejor equilibrio F1, aunque la V8 conservó el mayor mAP@50. Esta decisión refleja el compromiso entre precisión y exhaustividad: la V13 detecta menos elementos, pero sus predicciones son más fiables. Debido al tamaño todavía reducido del conjunto de prueba y a la concentración de falsos negativos en la clase pilar, los resultados se consideran una validación preliminar que requiere supervisión humana y futuras ampliaciones del dataset.

Fuentes de las figuras y datos

Todas las imágenes, métricas, matrices de confusión y configuraciones incluidas en este informe proceden de las capturas de pantalla del proyecto YOLO_ABADES_BUILDING compartidas por la autora y de los resultados mostrados por Roboflow. Las tablas y gráficos comparativos son de elaboración propia a partir de dichos resultados.